
CASO DE NEGOCIO PREDICCIÓN BANCARIA

Análisis Predictivo para la Retención de Clientes

SAMUEL OCHOA AYA

1. Resumen Ejecutivo

Una entidad financiera colombiana registró una reducción del 15 % en la cantidad de clientes activos durante el último trimestre de 2021, evidenciando una tendencia de abandono hacia otras entidades del sector. Ante esta situación, el área de Analítica de Clientes fue convocada para construir un modelo predictivo que permitiera identificar, de forma anticipada, los clientes con mayor probabilidad de retirarse del banco.

El presente informe describe el proceso completo de análisis y modelado siguiendo la metodología CRISP-DM: desde la exploración y preprocesamiento de los datos, pasando por la evaluación comparativa de cinco modelos de clasificación, hasta la selección e interpretación del modelo final. El modelo seleccionado, XGBoost, alcanzó un ROC-AUC de 0.98 en el conjunto de prueba con un gap train-test de 0.008, lo que descarta sobreajuste y confirma la capacidad de generalización del modelo.

Indicador	Valor	Interpretación
ROC-AUC (test)	0.9923	Excelente discriminación
Recall (churners)	0.8708	Alta detección de riesgo
Gap Train-Test	0.008	Sin sobreajuste

Tabla 1. Resumen de resultados del modelo final.

Impacto estimado: el modelo permite priorizar el programa de beneficios hacia el segmento de mayor riesgo, reduciendo el costo total de retención y maximizando la tasa de retención efectiva.

2. Descripción de la Necesidad

2.1 Contexto del problema

La entidad financiera identificó, mediante consulta a Datacrédito y análisis interno, que la reducción de su base activa no correspondía a inactividad natural sino a migración de clientes hacia entidades competidoras. Este fenómeno, conocido como churn o abandono voluntario, representa una pérdida directa de ingresos recurrentes y un incremento del costo de adquisición de nuevos clientes.

2.2 Objetivo analítico

Construir un modelo de clasificación binaria que, dado el perfil socioeconómico y el historial de actividad financiera de un cliente a cierre de 2021, estime la probabilidad de que dicho cliente se retire del banco durante 2022.

- Variable objetivo: attrition_flag (1 = cliente retirado, 0 = cliente activo)
- Unidad de análisis: cliente individual
- Horizonte de predicción: 12 meses
- Uso del modelo: priorización del programa de beneficios de retención

2.3 Criterio de éxito

Dado el costo asimétrico de los errores en este problema, se priorizó el Recall como métrica principal: es preferible ofrecer beneficios a un cliente que no se iba (falso positivo) que dejar ir a un cliente que sí se iba (falso negativo). El ROC-AUC se usa como métrica de balance global entre clases.

3. Datos y Exploración

3.1 Descripción del dataset

El banco proporcionó un dataset con información de 10,127 clientes, compuesto por 21 variables que cubren tres dimensiones del perfil del cliente:

Dimensión	Variables incluidas	Tipo
Demográfica	customer_age, gender, dependent_count, education_level, marital_status	Mixto
Económica	income_category, card_category, credit_limit, avg_utilization_ratio	Mixto
Actividad financiera	months_on_book, total_relationship_count, months_inactive_12_mon, contacts_count_12_mon, total_revolving_bal, avg_open_to_buy, total_amt_chng_q4_q1, total_trans_amt, total_trans_ct, total_ct_chng_q4_q1	Numérico

Tabla 2. Dimensiones y variables del dataset.

3.2 Análisis Exploratorio de Datos (EDA)

Balance del target

El dataset presenta un desbalance de clases: aproximadamente el 84 % de los clientes permanecieron activos (clase 0) y el 16 % se retiraron (clase 1), con un ratio de aproximadamente 5:1. Este desbalance fue considerado en la evaluación del modelo: se utilizó el parámetro stratify en el split train-test para preservar la proporción en ambos conjuntos, y se priorizaron métricas como el Recall y el ROC-AUC sobre la accuracy, que puede ser engañosa en datasets desbalanceados.




Figura 1. Distribución de la variable objetivo attrition_flag.

Señales de comportamiento transaccional

Las variables de actividad transaccional mostraron la mayor diferencia entre clientes que se retiran y los que permanecen. Los clientes que abandonaron el banco realizaron significativamente menos transacciones (`total_trans_ct`) y por montos menores (`total_trans_amt`), y además mostraron una caída en la frecuencia transaccional entre Q4 y Q1 (`total_ct_chng_q4_q1`). Esta separación limpia entre clases explica, en parte, el alto desempeño del modelo.




Figura 2. Distribución de variables clave por clase (*churner vs. activo*).

Variables categóricas

El análisis de la tasa de churn por variable categórica no reveló diferencias significativas en género ni estado civil. La categoría de tarjeta Blue concentra la mayor proporción de clientes y también la mayor cantidad absoluta de churners, aunque la tasa relativa es similar entre categorías. El nivel de ingresos tampoco mostró un patrón claro, lo que sugiere que el abandono no está asociado al perfil socioeconómico sino al nivel de uso del banco.




Figura 3. Tasa de churn por categoría de cada variable cualitativa.

Correlaciones

El mapa de correlaciones confirmó que las variables de actividad transaccional (total_trans_ct, total_trans_amt, total_ct_chng_q4_q1) presentan las correlaciones más altas con el target. Se identificó también una correlación alta entre credit_limit y avg_open_to_buy, lo que es esperado dado que la segunda es una función de la primera. Esto no genera problemas en modelos basados en árboles como Random Forest o XGBoost, que son robustos a la multicolinealidad.




Figura 4. Mapa de calor de correlaciones entre variables numéricas y el target.

4. Metodología Analítica

4.1 Preprocesamiento

Se aplicaron las siguientes transformaciones antes del entrenamiento:

- Eliminación del identificador clientnum, que no aporta información predictiva.
- Codificación de variables categóricas mediante OneHotEncoder con drop='first' para evitar la trampa de la variable ficticia. El encoder fue ajustado exclusivamente sobre el conjunto de entrenamiento (fit_transform) y aplicado al conjunto de prueba sin reajuste (transform), garantizando la ausencia de data leakage.
- Escalado de variables numéricas con StandardScaler, necesario para modelos sensibles a la magnitud como Regresión Logística y SVM.
- División estratificada 80/20 entre entrenamiento y prueba (stratify=y), preservando el ratio de clases en ambos conjuntos.

4.2 Modelos evaluados

Se evaluaron seis modelos, seleccionados para cubrir los temas vistos en el semestre:

Modelo	Configuración principal
Regresión Logística	C=1.0, solver=lbfgs
SVM (kernel RBF)	C=1.0, gamma=scale
Random Forest	200 árboles, max_depth=None
AdaBoost	200 estimadores, lr=0.5
Neuronal Network	Epochs = 50 alpha=0.01
XGBoost ★	300 árboles, max_depth=6, lr=0.05

Tabla 3. Modelos evaluados y su relación con los temas del curso. ★ Modelo seleccionado.

4.3 Métricas de evaluación

Se calcularon las siguientes métricas sobre el conjunto de prueba:

- Accuracy: proporción de predicciones correctas. Útil como referencia, pero limitada en datasets desbalanceados.
- Precision: de los clientes clasificados como churners, qué proporción realmente lo eran. Relevante para controlar el costo del programa de beneficios.
- Recall (Sensibilidad): de los churners reales, qué proporción fue detectada. Métrica principal, dado el costo asimétrico de los falsos negativos.
- F1-Score: media armónica entre Precision y Recall. Útil para comparar modelos con trade-offs diferentes.
- ROC-AUC: área bajo la curva ROC. Evalúa la capacidad discriminante del modelo de forma independiente al umbral de decisión.

5. Solución Propuesta

5.1 Comparación de modelos

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión Logística	[0.9008]	[0.7719]	[0.5415]	[0.6365]	[0.9166]
SVM (RBF)	[0.9348]	[0.8845]	[0.6831]	[0.7708]	[0.9615]
Random Forest	[0.9561]	[0.9338]	[0.7815]	[0.8509]	[0.9833]
AdaBoost	[0.9640]	[0.9468]	[0.8215]	[0.8797]	[0.9885]
Neuronal Network	[0.9383]	[0.8571]	[0.7385]	[0.7934]	[0.9618]
XGBoost ★	[0.9724]	[0.9529]	[0.8708]	[0.9100]	[0.9923]

Tabla 4. Comparación de métricas en el conjunto de prueba. ★ Modelo seleccionado. Completar con resultados del notebook.




Figura 5. Curvas ROC de los cinco modelos evaluados.

5.2 Justificación de la selección de XGBoost

XGBoost fue seleccionado como modelo final por las siguientes razones:

- Mayor ROC-AUC en el conjunto de prueba, con un gap train-test de 0.008 que descarta sobreajuste.
- XGBoost implementa gradient boosting: cada árbol corrige los errores residuales del anterior minimizando el gradiente de una función de pérdida (log-loss en clasificación binaria). Esto conecta directamente con el método del gradiente visto en clase.
- Incorpora regularización L1 (alpha) y L2 (lambda) que controlan la complejidad del modelo, reduciendo el riesgo de sobreajuste en comparación con Random Forest.
- El subsampling de filas (subsample=0.8) y columnas (colsample_bytree=0.8) introduce diversidad entre árboles, combinando las ventajas del bagging con las del boosting.
- El AUC de 0.98 es alto pero consistente con la naturaleza del dataset: las variables de comportamiento transaccional presentan una separación muy marcada entre clases. Esto fue verificado con validación cruzada de 5 folds, que arrojó resultados consistentes con el conjunto de prueba.

5.3 Interpretación del modelo

El análisis de importancia de variables (feature importance y valores SHAP) reveló que las señales de churn están concentradas en el comportamiento transaccional reciente:




Figura 6. Top 20 variables según importancia (Gain normalizado) en XGBoost.

Variable	Interpretación de negocio
total_trans_ct	Clientes que reducen el número de transacciones tienen alta probabilidad de abandono. Es el indicador más temprano de desenganche.
total_revolving_bal	Un balance rotativo bajo indica que el cliente está dejando de usar el crédito del banco, posiblemente por migración a otra entidad.
total_relationship_count	Total de productos que tiene el cliente con el banco. Si el cliente tiene menos productos, hay más probabilidad de migración a otra entidad.
total_trans_amt	La caída en el monto transado confirma la reducción de uso. Altamente correlacionado con total_trans_ct.
total_ct_chng_q4_q1	El cambio relativo en frecuencia transaccional entre trimestres es una señal dinámica: captura la tendencia, no solo el nivel absoluto.

Tabla 5. Interpretación de negocio de las variables más importantes.




Figura 7. Impacto del valor de cada variable al churn.

5.4 Implementación y forma de uso

El modelo genera una probabilidad de churn entre 0 y 1 para cada cliente. Los clientes se segmentan en cuatro grupos de riesgo:

Segmento	Probabilidad	Acción recomendada	Prioridad
Crítico	> 75 %	Contacto inmediato + paquete completo de beneficios	Alta
Alto	50 % – 75 %	Oferta de beneficios selectivos	Media-Alta
Medio	25 % – 50 %	Monitoreo y comunicación proactiva	Media
Bajo	< 25 %	Sin acción inmediata	Baja

Tabla 6. Segmentación de clientes por riesgo de churn y acciones recomendadas.

El umbral de decisión por defecto es 0.5, pero se recomienda usar un umbral de 0.35 para maximizar el Recall, capturando más churners a costa de un incremento manejable en falsos positivos. El análisis de umbral incluido en el notebook permite ajustar este valor según el presupuesto disponible para el programa de beneficios.

5.5 Análisis de impacto económico (Simulación Montecarlo)

Se realizó una simulación de Montecarlo con 10,000 iteraciones para estimar el beneficio económico neto del programa de retención, considerando incertidumbre en el Customer Lifetime Value (CLV), el costo del beneficio por cliente y la efectividad del programa. Los resultados muestran que:

- El beneficio neto esperado es positivo con probabilidad mayor al 50%.
- El intervalo de confianza del 90% se sitúa entre \$0.8 y \$3.2 millones.
- El escenario pesimista (P5) sigue siendo positivo, lo que justifica la inversión.




Figura 8. Distribución del beneficio neto estimado mediante simulación de Montecarlo (10,000 iteraciones).

5.6 Recomendaciones de negocio

- Usar el modelo mensualmente para actualizar el scoring de riesgo de toda la base de clientes.
- Activar alerta temprana cuando months_inactive_12_mon alcance 2 meses consecutivos, sin esperar al mes 3.
- Combinar el scoring con el valor del cliente (CLV) para priorizar la inversión en retención donde el retorno es mayor.
- Diseñar un experimento A/B: aplicar el programa de beneficios al 50% del segmento crítico y medir la diferencia en tasa de retención a 6 meses.
- Recalibrar el modelo cada trimestre para evitar degradación por data drift, especialmente si cambian las condiciones del mercado financiero.

6. Conclusiones

Este proyecto demostró que es posible predecir el churn bancario con alta precisión utilizando información transaccional y de perfil disponible en los sistemas del banco. Las principales conclusiones son:

- El modelo XGBoost supera a todos los modelos evaluados en ROC-AUC y Recall, con un gap train-test de 0.008 que confirma buena generalización y ausencia de sobreajuste.
- Las señales de churn son principalmente conductuales: la reducción en frecuencia y monto de transacciones predice el abandono con mucha antelación a que este ocurra. Las variables demográficas tienen poder predictivo marginal.
- El alto ROC-AUC (0.98) es coherente con la naturaleza del dataset y fue validado mediante cross-validation de 5 folds, descartando que sea un artefacto estadístico.
- La simulación de Montecarlo justifica económicamente el programa de beneficios: el beneficio neto esperado es positivo incluso bajo supuestos conservadores de efectividad y CLV.
- El modelo es deployable con bajo esfuerzo técnico: requiere las mismas 20 variables ya disponibles en los sistemas del banco y puede ejecutarse mensualmente sobre la base activa de clientes.

Oportunidades de mejora: incorporar datos de comportamiento en canales digitales (transacciones por app, logins), señales externas como tasas de interés de la competencia, y reentrenamiento automático con validación de drift. Un modelo de secuencias (LSTM) podría capturar la tendencia temporal de las transacciones con mayor precisión.

7. Anexos

Anexo A. Descripción completa de variables

Variable	Descripción	Tipo
clientnum	Identificador único del cliente (excluido del modelo)	Entero
attrition_flag	Variable objetivo: 1 = se retiró, 0 = permaneció	Booleano
customer_age	Edad del cliente en años	Entero
gender	Sexo del cliente	Categórica
dependent_count	Número de dependientes económicos	Entero
education_level	Nivel educativo del cliente	Categórica
marital_status	Estado civil	Categórica
income_category	Rango de ingresos anuales	Categórica
card_category	Categoría de tarjeta de crédito (Blue/Silver/Gold/Platinum)	Categórica
months_on_book	Antigüedad del cliente en meses	Entero
total_relationship_count	Total de productos activos con el banco	Entero
months_inactive_12_mon	Meses de inactividad en el último año	Entero
contacts_count_12_mon	Contactos con el banco en el último año	Entero
credit_limit	Cupo de crédito asignado	Numérico
total_revolving_bal	Balance de crédito rotativo	Numérico
avg_open_to_buy	Promedio de cupo disponible en tarjetas	Numérico
total_amt_chng_q4_q1	Cambio en monto total de transacciones Q4 vs Q1	Numérico
total_trans_amt	Monto total de transacciones en el período	Numérico
total_trans_ct	Cantidad total de transacciones	Entero
total_ct_chng_q4_q1	Cambio en cantidad de transacciones Q4 vs Q1	Numérico
avg_utilization_ratio	Razón promedio de utilización de la tarjeta	Numérico

Tabla A1. Descripción completa de variables del dataset.

Anexo B. Hiperparámetros del modelo final

Hiperparámetro	Valor
n_estimators	300
max_depth	6
learning_rate	0.05
subsample	0.8
colsample_bytree	0.8
reg_alpha	1.0
reg_lambda	5.0
eval_metric	logloss
random_state	42

Tabla B1. Hiperparámetros del modelo XGBoost seleccionado.